

Redes neuronales convolucionales para señales bursátiles

Clasificación de patrones Buy, Hold y Sell a partir de imágenes de series temporales

Resumen ejecutivo

El análisis transforma secuencias de precios de la acción de Loews Corporation en imágenes y utiliza redes neuronales convolucionales para clasificarlas en Buy, Hold o Sell. Se comparan tres arquitecturas con diferente profundidad y regularización, entrenadas con distintas cantidades de épocas. El trabajo permite evaluar cómo la complejidad del modelo y el número de iteraciones afectan accuracy y loss.

1. Objetivo y enfoque


El objetivo es explorar la capacidad de las CNN para reconocer patrones visuales construidos a partir de una serie financiera. En lugar de utilizar directamente una secuencia numérica, cada ventana de siete días se representa como una imagen. La etiqueta se determina con el movimiento del octavo día, convirtiendo un problema temporal en una tarea de clasificación multiclase.

2. Fundamentos de las redes convolucionales


Una red convolucional aplica filtros que recorren la imagen y producen mapas de características. Las primeras capas detectan patrones simples; las capas posteriores combinan esas señales para formar representaciones más complejas. MaxPooling reduce la resolución espacial y conserva los rasgos dominantes. Al final, las características se aplanan y pasan a capas densas que asignan probabilidades a Buy, Hold y Sell mediante una salida softmax.

3. Datos bursátiles

Se utilizan datos históricos de Loews Corporation desde el año 2000, con 6.254 días de actividad bursátil. El conjunto incluye apertura, cierre, máximo, mínimo, volumen, dividendos y splits. Para la generación de imágenes se selecciona el precio de cierre, mientras que los gráficos exploratorios permiten observar tendencia, volatilidad y volumen.



Evolución bursátil de Loews Corporation mediante velas y volumen.



Visualización complementaria de la serie y sus indicadores técnicos.

4. Construcción del dataset de imágenes

1. Selección de la columna Close y normalización min-max al intervalo $[0, 1]$.
2. Definición de una ventana de entrada de siete días y un umbral de variación de 2%.
3. Cálculo del promedio de cierre de los siete días de entrada.
4. Comparación del cierre del octavo día contra ese promedio.
5. Asignación Buy cuando la variación supera 2%, Sell cuando es inferior a -2% y Hold cuando se mantiene dentro de ese rango.
6. Generación de una imagen PNG por ventana, sin ejes y centrada en la forma de la tendencia.

7. Almacenamiento de las imágenes en carpetas separadas por etiqueta.

Etiqueta	Criterio	Imágenes
Buy	Variación superior a 2%	1.431
Sell	Variación inferior a -2%	1.148
Hold	Variación entre -2% y 2%	3.667
Total		6.246

La clase Hold representa aproximadamente 58,7% de las imágenes. Este predominio condiciona la interpretación de accuracy, ya que una parte relevante del desempeño puede provenir de aprender la clase mayoritaria.

5. Preparación del entrenamiento

Las imágenes se redimensionan a 100 x 100 píxeles con tres canales RGB. El generador utiliza batch size 128 y clasificación categórica. Se aplica data augmentation con zoom entre 0,8 y 1,2 y flip horizontal. Estas transformaciones buscan aumentar la variabilidad visual y reducir la dependencia de una representación exacta.

La función de pérdida es categorical crossentropy, el optimizador es Adam y la métrica principal es accuracy. El notebook registra las curvas de aprendizaje para comparar el efecto de aumentar las épocas.

6. Arquitecturas evaluadas

6.1 Modelo 1 - arquitectura profunda

Incluye cinco bloques Conv2D + MaxPooling2D con 16, 32, 64, 64 y 64 filtros. Luego utiliza Flatten, una capa Dense de 100 unidades y una salida softmax de tres neuronas. El modelo tiene 104.243 parámetros entrenables.

6.2 Modelo 2 - arquitectura compacta de mayor capacidad densa


Utiliza tres bloques Conv2D + MaxPooling2D con 16, 32 y 64 filtros, seguidos de Flatten, Dense de 64 unidades y salida softmax. La tabla consolidada registra 1.300.331 parámetros totales, de los cuales 433.443 son entrenables en la configuración resumida.

6.3 Modelo 3 - regularización con Dropout


Mantiene tres bloques convolucionales, pero agrega Dropout de 0,3, 0,3 y 0,4 después de las etapas de pooling. Antes de la salida incorpora una capa Dense de 64 unidades y Dropout de 0,5. La intención es reducir el sobreajuste mediante regularización explícita.

7. Resultados


Modelo	Épocas	Parámetros	Accuracy	Loss
Modelo 1	3	104.243	0.6881	0.7467
Modelo 1	5	104.243	0.5868	0.9283
Modelo 1	10	104.243	0.5495	1.9336
Modelo 2	3	1.300.331	0.6628	0.8093
Modelo 2	5	1.300.331	0.8322	0.3915
Modelo 3	3	433.443	0.5871	1.0536
Modelo 3	5	433.443	0.5871	1.0248



Curvas de entrenamiento del Modelo 1 para las configuraciones evaluadas.



Curvas de entrenamiento del Modelo 2.



Curvas de entrenamiento del Modelo 3 con Dropout.

8. Interpretación

La mejor combinación consolidada corresponde al Modelo 2 con cinco épocas, con accuracy 0,8322 y loss 0,3915. La configuración de tres épocas alcanza 0,6628 y 0,8093, respectivamente. El aumento de épocas mejora el ajuste del Modelo 2, aunque la ausencia de una validación temporal independiente impide concluir que la mejora se mantenga fuera del conjunto utilizado durante el entrenamiento.

El Modelo 1 obtiene 0,6881 de accuracy a tres épocas. En el registro detallado del entrenamiento, las ejecuciones de 3, 5 y 10 épocas se realizan de manera consecutiva sobre la misma instancia, por lo que los valores no representan entrenamientos completamente independientes desde pesos iniciales nuevos. Para una comparación estricta, cada configuración debería reinicializar el modelo.

El Modelo 3 se estabiliza alrededor de 0,5871, valor próximo a la proporción de la clase Hold. Esto sugiere que la regularización aplicada puede haber limitado demasiado la capacidad de aprendizaje o que el modelo se concentró en la clase mayoritaria.

9. Conclusiones y mejoras

- La transformación de series en imágenes permite aplicar visión por computadora a señales financieras.
- El Modelo 2 presenta el mejor ajuste reportado y el menor loss.
- La distribución de clases requiere métricas por clase, F1 macro y matriz de confusión además de accuracy.
- El entrenamiento y la evaluación deberían separarse temporalmente para evitar fuga de información.
- Cada configuración de épocas debe entrenarse desde una inicialización nueva para que la comparación sea homogénea.
- Las etiquetas se basan en umbrales académicos y no constituyen recomendaciones de inversión.

Fuentes de datos y herramientas

- [yfinance](#): obtención de datos históricos bursátiles utilizada en el código.
- [TensorFlow y Keras](#): construcción y entrenamiento de las CNN.
- [Loews Corporation](#): dataset de imágenes y archivos bursátiles incluidos en data/.
- [Código y resultados del proyecto](#): notebook, figuras y tabla comparativa incluidos en el repositorio.